



DEMI-JOURNÉE DATA SCIENCE



INTRODUCTION

Objectif : Évaluer la performance des méthodes de sélection de variables en régression linéaire.

Méthodes comparées : OLS (avec test de Student), Oracle (référence théorique), Recherche Exhaustive (Best Subset) et Stepwise (AIC/BIC).

Critères d'analyse : Efficacité à identifier le vrai modèle (Précision, Sensibilité, Spécificité du support S et à prédire (RMSE).

GENERATION DE DONNÉES

```
50  generate_lm <- function(n.train, p, p0, sigma2,
51                          n.test = 10 * n.train,
52                          structure = c("indep", "ar1", "block"),
53                          rho = 0, K = 5) {
54
55      structure <- match.arg(structure)
56
57      # Matrice de covariance
58      SigmaX <- make_SigmaX(p, structure, rho, K)
59
60      # Vrai vecteur de coefficients
61      beta_star <- make_beta(p, p0)
62
63      # Génération des prédicteurs X_train et X_test
64      X_train <- rmvnorm(n.train, mean = rep(0, p), sigma = SigmaX)
65      X_test  <- rmvnorm(n.test, mean = rep(0, p), sigma = SigmaX)
66
67      # Génération du bruit
68      eps_train <- rnorm(n.train, mean = 0, sd = sqrt(sigma2))
69      eps_test  <- rnorm(n.test, mean = 0, sd = sqrt(sigma2))
70
71      # Réponses
72      y_train <- as.vector(X_train %*% beta_star + eps_train)
73      y_test  <- as.vector(X_test  %*% beta_star + eps_test)
74
75      # Fusion dans un seul jeu complet
76      y_all <- c(y_train, y_test)
77      X_all <- rbind(X_train, X_test)
78
79      # Indices pour train/test
80      train_idx <- seq_len(n.train)
81      test_idx  <- n.train + seq_len(n.test)
```

```
5
6  # Fonction pour créer la matrice de covariance
7
8  make_SigmaX <- function(p, structure = c("indep", "ar1", "block"),
9                          rho = 0, K = 5) {
10      structure <- match.arg(structure)
11
12      # Cas 1 : variables indépendantes
13      if (structure == "indep" || rho == 0) {
14          return(diag(p))
15      }
16
17      # Cas 2 : dépendance de type AR(1)
18      if (structure == "ar1") {
19          Sigma <- outer(1:p, 1:p, function(i, j) rho^abs(i - j))
20          return(Sigma)
21      }
22
23      # Cas 3 : dépendance par blocs
24      if (structure == "block") {
25          Sigma <- diag(p)
26          block_size <- p / K
27
28          for (b in seq(1, p, by = block_size)) {
29              idx <- b:(b + block_size - 1)
30              Sigma[idx, idx] <- rho
31              diag(Sigma[idx, idx]) <- 1
32          }
33
34          return(Sigma)
35      }
36  }
37
```

GENERATION PAR BLOC


```
105  ✓ generate_lm_block <- function(n.train, p, p0, sigma2,  
106                                n.test = 10 * n.train, rho = 0.5, K = 5) {  
107    generate_lm(n.train, p, p0, sigma2, n.test,  
108              structure = "block", rho = rho, K = K)  
109  }
```

GENERATION PAR LONGITUDE


```
99  ✓ generate_lm_long <- function(n.train, p, p0, sigma2,  
100                                n.test = 10 * n.train, rho = 0.5) {  
101    generate_lm(n.train, p, p0, sigma2, n.test,  
102              structure = "ar1", rho = rho)  
103  }
```


Comparaison des structures de corrélation


Indépendant



AR(1) ($p = 0.6$)



Blocs ($p = 0.6$, $K = 4$)



SÉLECTION DE VARIABLES PAR LE TEST DE STUDENT

- ÉTUDIER LA CAPACITÉ DU TEST DE STUDENT À SÉLECTIONNER LES BONNES VARIABLES EXPLICATIVES DANS UN MODÈLE

MODÈLE LINÉAIRE SIMULÉ

Variable	β^*
X1	-1.49
X2	-1.45
X10	1.62
X3-X9	0

Paramètre	Valeur
n (observations)	100
p (variables)	10
p _o (variables actives)	3
σ^2 (variance du bruit)	1

```
List of 4
$ y      : num [1:100] 1.13 2.01 3.25 -3.32 -2.26 ...
$ X      : num [1:100, 1:10] -1.014 -0.791 0.3 1.639 1.085 ...
..- attr(*, "dimnames")=List of 2
.. ..$ : NULL
.. ..$ : NULL
$ beta   : num [1:10] -1.49 -1.45 0 0 0 ...
$ SigmaX: num [1:10, 1:10] 1 0 0 0 0 0 0 0 0 0 ...
[1] -1.492827 -1.447423 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 1.616343
```

STRUCTURE DES PRÉDICTEURS (SCÉNARIO PAR BLOCS)

```
List of 4
$ y      : num [1:100] 4.39 -2.5 1.13 -1.87 3.57 ...
$ X      : num [1:100, 1:12] -1.9562 0.0941 -0.7011 -0.6749 -0.0669 ...
..- attr(*, "dimnames")=List of 2
.. ..$ : NULL
.. ..$ : NULL
$ beta   : num [1:12] 0 0 0 0 0 ...
$ SigmaX: num [1:12, 1:12] 1 0.8 0.8 0.8 0 0 0 0 0 0 ...
[1] 0.000000 0.000000 0.000000 0.000000 0.000000 -1.647907 0.000000 0.000000 0.000000 0.000000 1.626770
[11] -1.972091 0.000000
      [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10] [,11] [,12]
[1,] 1.0 0.8 0.8 0.8 0 0 0 0 0 0 0 0
[2,] 0.8 1.0 0.8 0.8 0 0 0 0 0 0 0 0
[3,] 0.8 0.8 1.0 0.8 0 0 0 0 0 0 0 0
[4,] 0.8 0.8 0.8 1.0 0 0 0 0 0 0 0 0
[5,] 0.0 0.0 0.0 0.0 1 0 0 0 0 0 0 0
[6,] 0.0 0.0 0.0 0.0 0 1 0 0 0 0 0 0
[7,] 0.0 0.0 0.0 0.0 0 0 1 0 0 0 0 0
[8,] 0.0 0.0 0.0 0.0 0 0 0 1 0 0 0 0
[9,] 0.0 0.0 0.0 0.0 0 0 0 0 1 0 0 0
[10,] 0.0 0.0 0.0 0.0 0 0 0 0 0 1 0 0
[11,] 0.0 0.0 0.0 0.0 0 0 0 0 0 0 1 0
[12,] 0.0 0.0 0.0 0.0 0 0 0 0 0 0 0 1
```

SEUL LE PREMIER BLOC EST CORRÉLÉ,
LES AUTRES BLOCS SONT
INDÉPENDANTS.

- BLOC 1 -> VARIABLES X1 À X4,
CORRÉLÉES À $P = 0.8$

ÉVALUATION DES PERFORMANCES DE STUDENT

Performances du Test de Student :


Précision	Sensibilité	Spécificité	RMSE	Erreur_prédiction
0.6000	1.0000	0.7778	0.1124	3.9534

ON ÉVALUE ICI LA PERFORMANCE DU
TEST DE STUDENT SELON :


- SA CAPACITÉ DE SÉLECTION (BONNES VS MAUVAISES VARIABLES),
- ET SA CAPACITÉ PRÉDICTIVE (QUALITÉ DES PRÉDICTIONS SUR LES DONNÉES TEST).

ÉVALUATION DES PERFORMANCES


Erreur de prédiction selon la méthode



Erreur RMSE sur les coefficients estimés (β)



Précision du support sélectionné (variables pertinentes)




RECHERCHE EXHAUSTIVE BEST SUBSETS AVEC CRITÈRE CP, AIC ET BIC


Methode <chr>	RMSE <dbl>	Taille <int>	TP <int>	FP <int>
Cp	1.288008	6	4	2
AIC	1.288008	6	4	2
BIC	1.263961	4	4	0

3 rows


Recherche exhaustive — Critère Cp



Recherche exhaustive — AIC



Recherche exhaustive — BIC



ÉVALUATION DES PERFORMANCES

```
```{r}
perf <- function(X_test, y_test, beta, beta.star) {
 nzero <- which(beta != 0)
 zero <- which(beta == 0)
 true.nzero <- which(beta.star != 0)
 true.zero <- which(beta.star == 0)

 TP <- sum(nzero %in% true.nzero)
 TN <- sum(zero %in% true.zero)
 FP <- sum(nzero %in% true.zero)
 FN <- sum(zero %in% true.nzero)

 recall <- TP/(TP + FN)
 specificity <- TN/(FP + TN)
 precision <- TP/(TP + FP)

 recall[TP + FN == 0] <- NA
 specificity[TN + FP == 0] <- NA
 precision[TP + FP == 0] <- NA

 rmse <- sqrt(mean((beta - beta.star)^2, na.rm = TRUE))
 rerr <- sqrt(mean((y_test - X_test %*% beta)^2))

 res <- round(c(precision, recall, specificity, rmse, rerr), 4)
 res[is.na(res)] <- 0
 names(res) <- c("precision", "recall", "specificity", "rmse", "prediction")

 res
}
```
```

```
```{r}
source("methods.R")

X_train <- data3$X[data3$train,]
y_train <- data3$y[data3$train]
X_test <- data3$X[data3$test,]
y_test <- data3$y[data3$test]
beta_true <- data3$beta

Méthodes
beta_ols <- getOLS(X_train, y_train)
beta_best <- getBestSubset(X_train, y_train, criterion = "bic")
beta_aic <- getStepwiseAIC(X_train, y_train)
beta_bic <- getStepwiseBIC(X_train, y_train)
beta_lasso <- getLasso(X_train, y_train)
beta_oracle <- getOracle(X_train, y_train, beta_true)

Évaluation contre beta_true
res_tab <- rbind(
 OLS = perf(X_test, y_test, beta_ols, beta_true),
 BestSubset = perf(X_test, y_test, beta_best, beta_true),
 StepwiseAIC = perf(X_test, y_test, beta_aic, beta_true),
 StepwiseBIC = perf(X_test, y_test, beta_bic, beta_true),
 LASSO = perf(X_test, y_test, beta_lasso, beta_true),
 Oracle = perf(X_test, y_test, beta_oracle, beta_true)
)
res_tab
```
```

ÉVALUATION DES PERFORMANCES


| | precision | recall | specificity | rmse | prediction |
|-------------|-----------|--------|-------------|--------|------------|
| OLS | 0.2500 | 1 | 0.0000 | 0.1961 | 1.1386 |
| BestSubset | 0.6250 | 1 | 0.8000 | 0.1716 | 1.0978 |
| StepwiseAIC | 0.6250 | 1 | 0.8000 | 0.1716 | 1.0978 |
| StepwiseBIC | 0.6250 | 1 | 0.8000 | 0.1716 | 1.0978 |
| LASSO | 0.5556 | 1 | 0.7333 | 0.1373 | 1.0722 |
| Oracle | 1.0000 | 1 | 1.0000 | 0.0373 | 1.0067 |

- OLS MET QUASI TOUT NON-ZÉRO. COMME LES 5 VRAIES SONT DEDANS, RECALL=1, MAIS IL AJOUTE 15-0=15 FAUX POSITIFS → SPECIFICITY=0 ET PRECISION=5/20=0.25. MAUVAISE PARCIMONIE, PRÉDICTION MOYENNE.
- BESTSUBSET : ILS RETROUVENT LES 5 VRAIES (RECALL=1) MAIS AJOUTENT 3 FAUX POSITIFS → SPECIFICITY=12/15=0.80, PRECISION=5/(5+3)=0.625. MEILLEURE PARCIMONIE QUE OLS, PRÉDICTION CORRECTE.
- LASSO : TOUJOURS RECALL=1, MAIS UN PEU PLUS DE FP (ENVIRON 4), D'OÙ PRECISION 5/9. → MEILLEUR RMSE DES BETA ET MEILLEURE ERREUR DE PRÉDICTION PARMi LES MÉTHODES RÉALISTES.
- ORACLE : RÉFÉRENCE IDÉALE, CONNAIT LE VRAI SUPPORT. MEILLEUR SUR COEFFICIENTS ET PRÉDICTION (PROCHE DU BRUIT, ECART-TYPE = 1). SERT DE PLAFOND DE PERFORMANCE.

ÉVALUATION DES PERFORMANCES

```
```{r}
source("simulate.R")
set.seed(42)
res_indep <- map_dfr(1:10, ~ getOneSimu(.x, "indep"))
res_ar1 <- map_dfr(1:10, ~ getOneSimu(.x, "ar1", rho = 0.6))
res_block <- map_dfr(1:10, ~ getOneSimu(.x, "block", rho = 0.6))

res_all <- bind_rows(res_indep, res_ar1, res_block)
res_all
```
```




| method
<chr> | precision
<dbl> | recall
<dbl> | specificity
<dbl> | rmse
<dbl> | prediction
<dbl> | simu
<int> | structure
<chr> | rho
<dbl> |
|-----------------|--------------------|-----------------|----------------------|---------------|---------------------|---------------|--------------------|--------------|
| OLS | 0.2500 | 1 | 0.0000 | 0.0974 | 1.0718 | 1 | indep | 0.6 |
| BestSubset | 1.0000 | 1 | 1.0000 | 0.0270 | 0.9798 | 1 | indep | 0.6 |
| StepwiseAIC | 0.7143 | 1 | 0.8667 | 0.0614 | 1.0043 | 1 | indep | 0.6 |
| StepwiseBIC | 1.0000 | 1 | 1.0000 | 0.0270 | 0.9798 | 1 | indep | 0.6 |
| LASSO | 0.3846 | 1 | 0.4667 | 0.0552 | 1.0031 | 1 | indep | 0.6 |
| Oracle | 1.0000 | 1 | 1.0000 | 0.0270 | 0.9798 | 1 | indep | 0.6 |
| OLS | 0.2500 | 1 | 0.0000 | 0.1068 | 1.1492 | 2 | indep | 0.6 |
| BestSubset | 1.0000 | 1 | 1.0000 | 0.0696 | 1.0710 | 2 | indep | 0.6 |
| StepwiseAIC | 0.6250 | 1 | 0.8000 | 0.0947 | 1.1221 | 2 | indep | 0.6 |
| StepwiseBIC | 1.0000 | 1 | 1.0000 | 0.0696 | 1.0710 | 2 | indep | 0.6 |

1-10 of 180 rows

Previous 1 2 3 4 5 6 ... 18 Next

ÉVALUATION DES PERFORMANCES



- ORACLE : TOUJOURS LE PLUS BAS (AUTOUR DE 1) CAR IL CONNAÎT LE VRAI MODÈLE.
- LASSO, STEPWISEBIC ET BESTSUBSET ONT LES MEILLEURES PERFORMANCES PRÉDICTIVES APRÈS ORACLE.
- OLS EST SYSTÉMATIQUEMENT PLUS HAUT CAR IL INCLUT TROP DE VARIABLES, CE QUI AUGMENTE LA VARIANCE.

L'ERREUR DE PRÉDICTION AUGMENTE AVEC LA CORRÉLATION (AR(1) > BLOCK > INDEP).

EN PRÉSENCE DE VARIABLES CORRÉLÉES, LES MÉTHODES DE SÉLECTION ONT PLUS DE MAL À ESTIMER LES BONS COEFFICIENTS.